
Progetto Identificazione Modelli e Analisi Dati
Anno Accademico 2025/2026

MODELLAZIONE DEL CARICO ELETTRICO

INDICE

- **Esplorazione e Analisi Preliminare**
 - **Modellazione Termodinamica**
 - **Modellazione della Routine Umana**
 - **Modelli Multivariati e Reti Neurali**
-

ESPLORAZIONE E ANALISI PRELIMINARE


- **Analisi Dataset**
- **Pulizia delle Serie Storiche**
- **Analisi Visiva**

ANALISI DATASET

- **Orizzonte Storico:** 10 anni di registrazioni con campionamento orario.
- **Struttura Dati:** Timestamp, misurazioni del Carico Elettrico e rilevamenti termici da 25 stazioni meteorologiche indipendenti.
- **Variabile Target (Y):** Il Carico Elettrico (la domanda di energia da prevedere).
- **Variabili Predittive (X):** La Temperatura Media (calcolata sulle 25 stazioni) e l'Ora del Giorno.



TIMESTAMP	LOAD	w1	w2	w3	w4	w5	w6	w7	w8	w9
00		27	28	18	23	25	27	26	26	13
01		25	28	18	23	24	24	26	24	13
02		27	23	18	24	23	24	23	23	13
03		25	21	19	24	23	24	22	23	13
04		27	21	19	22	23	24	22	22	14
05		28	25	18	22	23	25	24	22	16

PULIZIA DELLE SERIE STORICHE



- **Gestione dei Macro-Vuoti (Drop):** Eliminazione del blocco storico iniziale privo di dati di carico per evitare distorsioni nell'addestramento.
- **Sincronizzazione (Resampling):** Allineamento rigoroso dei Timestamp tra le misurazioni di Carico e i sensori di Temperatura.
- **Gestione Anomalie (Imputation):** Interpolazione locale per i micro-buchi e filtraggio statistico dei picchi fuori scala (Outlier).
- **Prevenzione del Data Leakage:** Rigorosa esclusione di dati futuri per la correzione di errori passati.


ANALISI VISIVA



MODELLAZIONE TERMODINAMICA

- **Modelli Polinomiali basati sulla Temperatura Media**
 - **Implementazione delle Spline**
 - **Evoluzione Non Lineare**
 - **Algoritmi di Feature Selection**
-


MATRICE DI CORRELAZIONE



Correlazione Lineare Ingannevole

- Il **blu scuro** corrisponde a un valore molto basso, compreso tra 0.1 e 0.2. Questo indica che c'è una correlazione lineare debolissima tra il carico elettrico e le temperature. Questo non vuol dire che la temperatura non influenzi il carico elettrico.
- Il **giallo** corrisponde a valori tra 0.9 e 1.0 sulla barra laterale. Questo dimostra che le 25 variabili di temperatura sono fortemente correlate positivamente tra di loro.

MODELLI POLINOMIALI BASATI SULLA TEMPERATURA



Command Window


--- VALUTAZIONE UNIFICATA MODELLI POLINOMIALI ---
Addestramento (Random CV) su 80% dei dati storici. Validazione su 20%.

Grado	AIC_Teorico	FPE_Teorico	RMSE_Empirico_Test
1	4.2342e+05	2140.8	46.206
2	3.7258e+05	606.31	24.472
3	3.6936e+05	559.75	23.63
4	3.6816e+05	543.2	23.216
5	3.6816e+05	543.24	23.186

=> CONCLUSIONE:
Secondo la validazione empirica, il modello polinomiale migliore è il Grado 5.
Generazione grafico del miglior modello polinomiale...


- **Ricerca Polinomiale:** Test ai minimi quadrati (Grado 1-5). Il Grado 5 minimizza l'errore (RMSE: 23.18) e l'AIC.

FALLIMENTO DEI MODELLI POLINOMIALI








- **Il Fallimento Fisico:** Nonostante le metriche, la curva del Grado 5 fallisce agli estremi: prevede un calo irrealistico dei consumi al di sotto dei 20°F.
- **Soluzione:** Regression Spline

IMPLEMENTAZIONE DELLE SPLINE




- **Ricerca del Nodo Termico:** Identificazione matematica della "valle del comfort" a 59.65 °F.
- **Spline Lineare (Ramo Freddo + Ramo Caldo):** Separazione fisica del riscaldamento e del condizionamento (RMSE: 24.89)

EVOLUZIONE NON LINEARE



- **Evoluzione Non Lineare:** L'uso di archi quadratici (curva rossa) modella l'inerzia termica, ottenendo la geometria fisicamente perfetta e il miglior RMSE delle spline (23.12).

ANALISI DEI RESIDUI





- L'analisi conferma che la sola temperatura media è insufficiente a descrivere la complessità del carico elettrico. L'evidente pattern ciclico giustifica la necessità di espandere l'architettura predittiva, passando a un modello che integri l'uso di serie armoniche.

ALGORITMI DI FEATURE SELECTION

```
--- RISULTATI CONFRONTATI (Validati sul Validation Set) ---
                                     Selected_Variables  RMSE_Validation_Set
                                     _____  _____
Forward (Lin)                        10                44.449
Backward (Lin)                       15                44.405
Hybrid (Lin)                         15                44.405
LASSO (Spline MinMSE)                44                37.915
```

- Il secondo approccio, più esplorativo, prevede l'uso di tecniche di **Feature Selection regolarizzate**, come la **regressione LASSO** o la **Stepwise**.
- Si evince dall'immagine che la **regolarizzazione LASSO** ha **RMSE più basso**, ma perché usa 44 variabili se disponibili sono solo 25?

LASSO - LEAST ABSOLUTE SHRINKAGE AND SELECTION OPERATOR




- **Cerchio Verde:** Modello con 44 variabili, che rappresentano rami caldi e freddi, ha un RMSE più basso.
- **Cerchio Blu:** Modello con una ventina di variabili, aumenta RMSE di una frazione decimale totalmente trascurabile riducendo dimensionalità del modello ma resistenza all'overfitting.

MODELLAZIONE DELLA ROUTINE UMANA


- **Modelli Polinomiali basati sull'Ora del Giorno**
 - **Il Problema della Ciclicità Giornaliera**
 - **Soluzione Armonica**
-

MODELLI POLINOMIALI BASATI SULL'ORA DEL GIORNO




- **Andamento della routine:** La distribuzione dei dati mostra una chiara "doppia gobba". Si osservano consumi minimi notturni, una salita al mattino e un picco massimo concentrato nelle ore serali.
- **Modello Polinomiale:** L'algoritmo identifica nel Polinomio di Grado 5 il miglior modello per questo andamento orario (**RMSE: 42.94**).

IL PROBLEMA DELLA CICLICITÀ GIORNALIERA



- **Limite concettuale:** I polinomi sono rigidi per natura e non sono funzioni cicliche.
- **Discontinuità fisica:** Emerge un difetto critico agli estremi (ore 0 e 24). La curva parte da un carico di circa 125, ma crolla in modo del tutto innaturale verso quota 95 alla mezzanotte successiva.

SOLUZIONE ARMONICA





- A differenza del polinomio, il modello armonico (curva rossa) garantisce la perfetta continuità agli estremi. Il carico stimato alle 23:59 si raccorda in modo esatto e naturale con quello delle 00:00.
- L'onda armonica insegue con estrema naturalezza la forma dei dati, catturando fedelmente il fisiologico calo notturno, la ripresa mattutina e il picco massimo del tardo pomeriggio.
- Nonostante l'ottimo fit temporale, **la dispersione cromatica verticale evidenzia che l'ora da sola non basta a spiegare il fenomeno**: a parità di orario, le temperature estreme arrivano a raddoppiare il carico elettrico.

MODELLI MULTIVARIATI E RETI NEURALI


- **L'interazione Dinamica tra Meteo e Orario - Polinomio Multivariato**
- **La Creazione del Master Model**
- **Confronto con una Rete Neurale**

L'INTERAZIONE DINAMICA TRA METEO E ORARIO



- Si osserva chiaramente che il vertice di minimo consumo (la "valle") non è fisso, ma si sposta.
- Un modello additivo semplice ($T + t$) è inadeguato; è matematicamente necessaria un'interazione moltiplicativa ($T \times t$).


PERFORMANCE MODELLO ARMONICO SU DATI FUTURI




- **Validazione su dati futuri:** Il modello dimostra un'elevata capacità di generalizzazione su un campione di 3 giorni non utilizzati in fase di training
- **Efficacia dell'Interazione:** La precisione nel catturare l'ampiezza dei picchi conferma che l'impatto della temperatura sul carico è funzione dell'ora del giorno.
- **Il valore di RMSE (19.19)** valida matematicamente l'intuizione di unire fisica termodinamica e routine umana.

IL POLINOMIO MULTIVARIATO

Modello 3D Additivo: Spline Non Lineare (Temp) + Spline Oraria (Tempo)




Superficie del Modello Multivariato Additivo (RMSE Val: 17.88)



```
=====
--- PUNTO 6: IL MODELLO FINALE (TEMPERATURA + TIMESTAMP) ---


=> RIEPILOGO PERFORMANCE (Validation Set):
1. Modello Base Termico (Polinomio Grado 5):          23.19
2. Modello Base Temporale (Polinomio Grado 5):         42.94
3. Modello Multivariato Additivo (Temp + Tempo):       17.88
4. Modello Armonico con Interazione (Temp x Tempo):   19.19
5. Modello 3D Additivo (Spline NL + Spline Oraria):   19.38
=====
```


LA CREAZIONE DEL MASTER MODEL



- Modello Grey Box che fonde Spline Non Lineari (meteo) e Serie di Fourier (tempo).
- Risultato: **RMSE sceso a 15.17.**
- Geometria perfetta: la "valle" termica è morbida e la continuità temporale tra le giornate è rispettata rigorosamente.

CONFRONTO CON UNA RETE NEURALE



- Una Rete Neurale Feed-Forward a 15 neuroni abbassa ulteriormente l'**RMSE a 14.68**, imparando da sola la topologia della superficie.
- **La Scelta Ottimale:** Il Master Model cede una frazione di precisione (15.17 contro 14.68) ma garantisce totale interpretabilità e stabilità.

CONCLUSIONI

Modello	Regressori	RMSE Val.	Param.
Polinomio G5	Temp. Media	23.18	6
Spline Lineare	Temp. Media (Hinge)	24.89	3
Spline Non Lin.	Temp. Media (Quadr.)	23.12	5
Stepwise (Fwd)	25 Stazioni	44.45	10
LASSO	50 Basi Spline	37.91	44
Armonico	Ora (Fourier)	19.19	15
Master Model	Temp + Ora + Int	15.17	47
Rete Neurale	Temp + Ora	14.68	76

GRAZIE PER L'ATTENZIONE

Q&A

TABELLA DEI COEFFICIENTI OLS

PUNTO 4: SELEZIONE DELLE VARIABILI E GESTIONE COLLINEARITA'

RIDUZIONE DEL COSTO COMPUTAZIONALE (SUBSAMPLING)

Al fine di abbattere il costo computazionale e i tempi di calcolo,
è stato applicato un campionamento casuale (subsampling) al training set.

-> Numero iniziale di osservazioni: 40300

-> Numero finale di osservazioni utilizzate: 4030 (10%)

ANALISI OLS: IL PROBLEMA DELLA MULTICOLLINEARITA'

Fit di un modello lineare (Minimi Quadrati Ordinari) con tutte le 25 stazioni.

=> SINTESI: 13 coefficienti su 25 (52.0%) risultano NON significativi (p-value > 0.05).



Questo conferma l'elevata ridondanza e l'instabilità del modello globale.

Di seguito un estratto dei coefficienti OLS (Stima, Errore Standard, p-Value):

	Estimate	SE	tStat	pValue
(Intercept)	109.44	3.7376	29.28	6.119e-171
x1	-0.13815	0.19319	-0.71513	0.47457
x2	0.90139	0.24261	3.7154	0.00020567
x3	-0.062115	0.19996	-0.31063	0.75609
x4	-0.11119	0.42945	-0.25892	0.79571
x5	1.0864	0.26049	4.1706	3.1018e-05
x6	-0.70536	0.32324	-2.1822	0.029154
x7	0.39287	0.39797	0.9872	0.3236
x8	0.41764	0.23678	1.7639	0.077832
x9	-0.42709	0.1683	-2.5376	0.011199
x10	0.96138	0.28871	3.33	0.00087646
x11	-0.33837	0.34153	-0.99076	0.32186
x12	-0.87851	0.26853	-3.2715	0.0010787
x13	-0.30737	0.18647	-1.6484	0.099347
x14	0.76266	0.2254	3.3836	0.00072225
x15	-1.0472	0.35563	-2.9446	0.0032525
x16	-1.5545	0.30607	-5.0789	3.9689e-07
x17	0.64126	0.39596	1.6195	0.10541
x18	-0.36552	0.31112	-1.1748	0.24013
x19	1.2815	0.21176	6.0519	1.5629e-09
x20	-0.48543	0.38163	-1.272	0.20345
x21	-0.092642	0.24703	-0.37503	0.70766
x22	-0.34833	0.33142	-1.051	0.2933
x23	-1.4334	0.27379	-5.2354	1.7308e-07
x24	1.8771	0.40852	4.5948	4.4659e-06
x25	0.5634	0.36424	1.5468	0.122

- Riduzione del costo computazionale:** Per velocizzare l'addestramento e i test, il dataset è stato inizialmente sottoposto a subsampling, passando da 40.300 a 4.030 osservazioni (mantenendo un campione rappresentativo del 10%).
- Risultato critico (P-value):** L'output statistico rivela che la maggioranza dei regressori fallisce il test di significatività. Esattamente 13 coefficienti su 25 (ovvero il 52% del totale) presentano un p-value superiore alla soglia critica dello 0.05.
- Diagnosi di instabilità:** Questo alto tasso di bocciatura non significa che le temperature siano inutili per la previsione. Al contrario, dimostra in modo inequivocabile l'elevata ridondanza e l'instabilità del modello dovuta alla multicollinearità. Le stazioni misurano variazioni termiche troppo simili tra loro.

OTTIMIZZAZIONE ARMONICHE



- **Ottimizzazione del parametro "k":** Il primo grafico mostra la ricerca del numero ideale di frequenze (armoniche) per il modello temporale. Minimizzando il Criterio di Informazione di Akaike (AIC), l'algoritmo individua in $k=7$ il valore teorico ottimale.
- Osservando la curva blu dell'AIC, si nota come l'errore crolli drasticamente passando da 1 a 2 armoniche, per poi rimanere quasi "piatto". Questo suggerisce che basterebbero 2 o 3 frequenze per catturare la macro-routine quotidiana, mentre un $k=7$ rischia di modellare rumore irrilevante.
- **La falla fisica delle Spline:** Nel secondo grafico, la Spline Oraria (linea blu tratteggiata) evidenzia il suo più grande limite strutturale: non chiude il ciclo. Al contrario, il Modello Armonico (linea rossa continua) è governato da funzioni sinusoidali che garantiscono la periodicità. Le estremità della curva si raccordano in modo fluido ed esatto, rispettando la natura ciclica dei giorni e delle stagioni umane.