

Progetto IMAD Modellazione Carico Elettrico

Considerazioni

Matteo Morello

Indice

1	Punto 1	2
1.1	Esplorazione dei Dati	2
2	Punto 2	3
2.1	Calcolare la Matrice di Correlazione	3
3	Punto 3	5
3.1	Criteri Informativi e Metodi di Validazione	5
3.2	Svolgimento: Random Cross-Validation	5
3.3	La Random Cross-Validation è la scelta migliore?	6
3.4	Osservazione del grafico: Errore Sulla Coda	7
3.5	Evoluzione della Spline Lineare	9
3.6	Goodness of Fit	11
3.7	Analisi dei Residui	12
4	Punto 4	13
4.1	Il problema di fondo - La Collinearità	13
4.2	Le soluzioni	13
4.2.1	Stepwise	14
4.2.2	Regolarizzazione LASSO - Least Absolute Shrinkage and Selection Operator	14
5	Punto 5	17
5.1	Grafico del Modello LOAD - TIME	17
5.2	Soluzione - Modello Armonico	18
6	Punto 6	20
6.1	Intuizione	20
6.2	Performance Modello Armonico su dati Futuri	22
6.3	Superficie 3D	23
7	Punto 7	24
7.1	Modello finale e Rete Neurale	24
8	Conclusioni e Sviluppi Futuri	25
8.1	Conclusioni	25
8.2	Sviluppi Futuri: Recupero dell'Informazione Spaziale Sintetica	25

1 Punto 1

Fare il grafico del carico nel tempo, della temperatura media nel tempo e del carico in funzione della temperatura media;

1.1 Esplorazione dei Dati




Figura 1

- **Figura a:** Nei primi due pannelli abbiamo analizzato la dispersione del Carico e della Temperatura rispetto all'ora del giorno. Si nota subito una fortissima stratificazione verticale: a parità di ora, i valori oscillano enormemente, indicando che l'orologio da solo non basta a spiegare il fenomeno. La vera rivelazione si trova nel terzo pannello in basso: il Carico in funzione della Temperatura. Qui emerge chiaramente una relazione non lineare a forma di 'U' o 'V'. Notiamo una 'valle' di bassi consumi attorno ai 60°F, che corrisponde alla temperatura di comfort naturale, e due ripide salite ai lati causate dall'accensione dei sistemi di riscaldamento (a sinistra) e di condizionamento (a destra).
- **Figura b:** Nel pannello inferiore, l'andamento della temperatura mostra la perfetta e rassicurante macro-stagionalità annuale, con le sue costanti onde sinusoidali che scandiscono le estati e gli inverni nel corso degli anni. Nel pannello superiore, guardando il carico elettrico, l'andamento stagionale è ugualmente visibile, ma emerge un dettaglio critico: c'è un enorme vuoto di registrazioni nei primi anni del dataset. Dalla serie temporale si osserva la presenza di intervalli con dati mancanti. Prima della fase di modellazione sono quindi state considerate soltanto le osservazioni complete, per le quali risultano disponibili sia il valore di LOAD sia le misure di temperatura richieste.

2 Punto 2

Calcolare una matrice di correlazione tra le variabili di temperatura e LOAD;

2.1 Calcolare la Matrice di Correlazione

L'analisi di correlazione è uno strumento statistico fondamentale prima di addestrare qualsiasi modello di regressione. Lo facciamo per due scopi principali:

1. Quantificare la relazione tra Predittori e Target (Temperature vs. LOAD):

Vogliamo misurare matematicamente quanto ogni singola stazione meteo ($w_1 \dots w_{25}$) sia legata al carico elettrico (LOAD). Il coefficiente di correlazione di Pearson, indicato con r , valuta la forza e la direzione di una relazione lineare tra due variabili continue, restituendo un valore tra -1 e +1. Tuttavia, come abbiamo visto dallo scatter plot a forma di "U", sappiamo già che la relazione temperatura-carico non è strettamente lineare. In questo caso, otterremo probabilmente coefficienti di correlazione bassi o prossimi allo zero, ma questo non significa che non ci sia relazione, bensì che la relazione è non lineare (quadratica).

2. Individuare la Multicollinearità tra i Predittori (Temperatura vs. Temperatura):

Calcolando la matrice di correlazione, potremo vedere quanto le 25 stazioni meteo sono correlate tra di loro. Inserirle tutte in una regressione ai minimi quadrati causerebbe instabilità numerica e coefficienti non significativi (il modello non saprebbe a quale delle variabili attribuire il peso).

Se la stazione w_1 e la stazione w_2 registrano sempre temperature quasi identiche (perché sono geograficamente vicine), le loro curve salgono e scendono all'unisono. Quando il carico elettrico (LOAD) sale, il modello non ha matematicamente modo di distinguere se il merito è esclusivamente dell'incremento di w_1 o di w_2 .




Figura 2: Heatmap delle correlazioni tra le stazioni

Interpretazione immagine

1. La prima riga/colonna blu: Il limite della Correlazione Lineare

- **Cosa significa:** Guardando la barra laterale (colorbar), il blu scuro corrisponde a un valore molto basso, compreso tra 0.1 e 0.2. Questo indica che c'è una correlazione lineare debolissima tra il carico elettrico e le temperature.

Questo non vuol dire che la temperatura non influenzi il carico elettrico. L'indice di Pearson (su cui si basa questa matrice) è "cieco" alle curve a U; riesce a vedere solo le linee rette.

2. Il blocco giallo: La prova della Multicollinearità

- **Cosa significa:** Il giallo corrisponde a valori tra 0.9 e 1.0 sulla barra laterale. Questo dimostra che le 25 variabili di temperatura sono fortemente correlate positivamente tra di loro. In pratica, quando la temperatura sale alla stazione 1, sale quasi in modo identico anche nelle altre 24 stazioni. Questo blocco giallo ci avverte visivamente che se inserissimo tutte e 25 le variabili in un modello di regressione standard, l'algoritmo non riuscirebbe a distinguere il contributo dell'una rispetto all'altra, portando a stime instabili e alla "non significatività di alcuni coefficienti".

3 Punto 3

Fittare modelli polinomiali ai minimi quadrati di LOAD in funzione di $w(t)$, confrontando diversi gradi tramite cross-validation, test F, AIC, FPE o MDL;

3.1 Criteri Informativi e Metodi di Validazione

Questa fase serve a risolvere formalmente il problema della relazione non lineare (la forma a "U") e a trovare il "giusto mezzo" per evitare l'overfitting.


Per scegliere il grado del polinomio si possono usare criteri informativi, come **AIC**, **FPE** o **MDL**, oppure metodi di validazione, come la cross-validation. Entrambi gli approcci cercano un compromesso tra accuratezza sui dati disponibili e complessità del modello. Nel seguito si confrontano i modelli tramite questi criteri, tenendo presente che la valutazione finale sarà effettuata su dati temporalmente successivi.

3.2 Svolgimento: Random Cross-Validation

La Random Cross-Validation è una tecnica statistica fondamentale per valutare la capacità di generalizzazione di un modello predittivo. Il suo scopo principale è di stimare la capacità di generalizzazione del modello e a ridurre il rischio che il modello impari il rumore specifico del training set.

Lo svolgimento operativo si articola in quattro fasi sequenziali:

1. **Campionamento Casuale (Shuffling)**: L'intero dataset (comprendente storici di carico, temperature e orari) viene rimescolato casualmente. Questo passaggio è cruciale per eliminare eventuali bias legati all'ordinamento originale dei dati, distruggendo pattern spuri e garantendo un campione eterogeneo.
2. **Partizionamento (Splitting)**: I dati rimescolati vengono divisi in due sottoinsiemi mutuamente esclusivi. Nel nostro studio è stata adottata la classica proporzione statistica dell'80/20, Training Set (80% dei dati) e Validation Set (20% dei dati)
3. **Addestramento (Training)**: I vari modelli proposti vengono addestrati o stimati sui dati di training.
4. **Validazione Empirica (Testing)**: Il modello ormai addestrato viene interrogato chiedendogli di prevedere il carico elettrico per le osservazioni presenti nel Validation Set. Le previsioni generate vengono confrontate con i valori reali misurando l'errore quadratico medio radicolare (RMSE).



(a)

Command Window			
--- VALUTAZIONE UNIFICATA MODELLI POLINOMIALI ---			
Addestramento (Random CV) su 80% dei dati storici. Validazione su 20%.			
Grado	AIC_Teorico	FPE_Teorico	RMSE_Empirico_Test
1	4.2342e+05	2140.8	46.206
2	3.7258e+05	606.31	24.472
3	3.6936e+05	559.75	23.63
4	3.6816e+05	543.2	23.216
5	3.6816e+05	543.24	23.186

=> CONCLUSIONE:
Secondo la validazione empirica, il modello polinomiale migliore è il Grado 5.
Generazione grafico del miglior modello polinomiale...

(b)

Figura 3

3.3 La Random Cross-Validation è la scelta migliore?

No, è una semplificazione. Migliore Time Series Cross-Validation perchè in questi scenari, la tradizionale Random Cross-Validation rischia di causare "data leakage" (fuoriuscita di informazioni), poiché il modello potrebbe usare inavvertitamente dati del "futuro" per prevedere il "passato".

Svolgimento:

1. **Ordinamento Cronologico Rigoroso:** Il dataset non viene mai rimescolato. Le osservazioni rimangono nel loro esatto ordine storico (es. dal 2010 al 2020), preservando l'autocorrelazione naturale del fenomeno.
2. **Definizione della Finestra Iniziale:** Si seleziona un blocco continuo di dati passati come primo Training Set (es. i primi 3 anni di storico) e il blocco immediatamente successivo come Validation Set (es. il mese o l'anno seguente).
3. **Fase di Addestramento e Previsione:** Il modello viene addestrato sul Training Set iniziale e genera le previsioni sul Validation Set adiacente. Si calcola e si memorizza l'errore (RMSE) per questa specifica iterazione.
4. **Scorrimento della Finestra (Rolling Origin):** Il confine tra Training e Validation viene spostato in avanti nel tempo. I dati appena usati per il test vengono inglobati nel nuovo Training Set, permettendo al modello di "aggiornare" la sua conoscenza, e si definisce un nuovo Validation Set nel futuro immediato.
5. **Iterazione e Calcolo Medio:** I passi 3 e 4 vengono ripetuti fino all'esaurimento del dataset. L'errore finale del modello è dato dalla media degli RMSE calcolati in ciascun "passo" temporale.

3.4 Osservazione del grafico: Errore Sulla Coda




Figura 4: Il modello non segue la realtà

Nonostante il modello polinomiale di grado 5 sia il modello che approssima meglio i dati, noto che sulla coda sinistra non segue la nuvola delle misurazioni per cui matematicamente è valido ma per la realtà e la fisica c'è una severa discordanza. All'aumentare del grado, quindi della flessibilità, un polinomio globale può presentare oscillazioni nelle zone di coda del dominio, soprattutto dove sono presenti meno dati.

Soluzione

Confronto il modello di grado inferiore (4°) e la Regression Spline.

1. **Il confronto tra Grado 4 e Grado 5:** Il polinomio di grado 5, essendo più flessibile, può adattarsi meglio alla parte centrale dei dati, ma può anche assumere andamenti meno stabili nelle zone di coda, dove le osservazioni sono più rare. Il polinomio di grado 4 ha un grado di libertà meno e può quindi risultare meno oscillatorio, ma non necessariamente cattura con la stessa accuratezza la curva osservata nei dati.
2. **La soluzione della Regression Spline:** Per superare i limiti fisici dei modelli polinomiali globali, ho individuato analiticamente il punto di minimo dei consumi, che assume il ruolo di "nodo" (k) per la costruzione della Spline Lineare. Per fittare questo modello a pendenze separate tramite i minimi quadrati (lsco), ho costruito la Matrice dei Regressori (o **Matrice di Sensitività**) introducendo le cosiddette hinge functions (funzioni cerniera). Nello specifico, l'algoritmo utilizza la funzione $\max()$ per generare un regressore aggiuntivo formulato come:

$$(w - k)_+ = \max(w - k, 0)$$

ove w rappresenta la temperatura media e k è il nodo della spline. Questa funzione permette alla pendenza della curva di "spezzarsi" esattamente in corrispondenza del nodo termico.

Il modello matematico assume quindi la seguente struttura:

$$\text{LOAD} = \beta_0 + \beta_1 w + \beta_2(w - k)_+ + \varepsilon$$

In questo modo, il significato dei regressori inseriti nella matrice diventa fisicamente interpretabile:

- **Prima del nodo termico** ($w \leq k$): La hinge function si annulla (restituisce 0). La pendenza della curva è data esclusivamente da β_1 , che modella l'efficienza e l'attivazione dei sistemi di riscaldamento invernali.
- **Dopo il nodo termico** ($w > k$): La hinge function si attiva. La pendenza della curva subisce una transizione e diventa $\beta_1 + \beta_2$, modellando la diversa efficienza e il maggiore impatto energetico dei condizionatori estivi.

Il risultato è un modello costituito da una retta con pendenza negativa a sinistra e una retta più ripida a destra. Una possibile interpretazione è che il carico aumenti sia per temperature basse sia per temperature alte, coerentemente con una maggiore domanda energetica in condizioni climatiche più estreme. Tuttavia, non avendo informazioni dettagliate sulla facility, questa interpretazione deve essere considerata qualitativa.




Figura 5: Spline Lineare

3.5 Evoluzione della Spline Lineare




Figura 6: Confronto tra 4°, 5° e Spline

--- CREAZIONE MODELLI AVANZATI E SPLINE ---

Punto di minimo (Knot) per la Spline trovato a: 59.65 °F

RMSE Spline Lineare: 24.89

RMSE Spline NON Lineare (Archi): 23.12

Figura 7: Console MatLab

L'introduzione di una base Spline Lineare ha rappresentato un primo e fondamentale passo per la corretta modellazione del carico elettrico, permettendo di superare l'eccessiva rigidità dei regressori polinomiali globali. Fissando un "nodo termico" (o knot, corrispondente alla temperatura di comfort e di minimo assorbimento di rete), la spline lineare divide il dominio in due regimi distinti: il ramo invernale (guidato dal riscaldamento) e il ramo estivo (guidato dal raffrescamento). Tuttavia, l'assunzione di una risposta termica strettamente lineare presenta due limiti:

1. **Discontinuità della derivata:** La spline lineare genera una forma a "V" netta in corrispondenza del nodo k . Nella realtà fisica, il passaggio dalla necessità di riscaldamento a quella di raffrescamento avviene in modo graduale e fluido (una forma a "U"), senza bruschi cambi di pendenza.
2. **Sottostima degli estremi termici:** Al raggiungimento di temperature estreme (ondate di gelo o di calore severo), lo sforzo termodinamico richiesto per mantenere costanti le temperature interne degli edifici cresce in modo più che proporzionale, portando a un assorbimento elettrico accelerato.

Per catturare questa dinamica convessa, il modello è stato evoluto in una Spline Non Lineare (Quadratica). L'architettura è stata arricchita affiancando ai regressori lineari le loro controparti elevate al quadrato, permettendo così alla curva di "piegarsi" e assecondare la rapida impennata dei consumi agli estremi del dominio.

Interpretazione

1. **Punto di minimo (Knot) trovato a: 59.65 °F** L'individuazione del nodo termico (k) per la costruzione della spline non è stata effettuata in modo arbitrario.

- (a) Si è generato un asse delle temperature artificiale, suddiviso in 200 punti equidistanti che coprono l'intero range termico, dalla temperatura minima alla massima registrata.
- (b) Il modello polinomiale di Grado 5 ha previsto il carico su questo nuovo asse simulato. Il risultato è stato una curva a "U" perfettamente liscia, depurata da qualsiasi rumore e varianza dei sensori.
- (c) Attraverso una funzione di minimizzazione applicata a questa curva simulata, l'algoritmo ha individuato la posizione esatta del punto più basso.

È la cosiddetta "temperatura di comfort termico" della rete elettrica analizzata. Significa che a circa 60 gradi Fahrenheit.

L'algoritmo ha preso questo esatto numero e lo ha usato come perno (il nodo della spline) per spaccare la nuvola di punti in due. Tutto ciò che sta a sinistra di 59.65 °F viene trattato come "comportamento invernale" (la retta scende), tutto ciò che sta a destra viene trattato come "comportamento estivo" (la retta sale).

2. RMSE del modello Spline Lineare e NON Lineare

In media, quando uso questa "V" asimmetrica per prevedere i consumi, errore di circa 24.89 Megawatt, mentre per la versione non lineare ho un errore di 23.12 e una forma più a parabola del grafico.

Anche se l'errore numerico (RMSE) tra il Grado 5 e la Spline è simile, la Spline è nettamente superiore dal punto di vista della termodinamica. Il polinomio rischiava di fare curve irrealistiche agli estremi (overfitting), mentre la Spline garantisce che all'aumentare o al diminuire delle temperature, il carico si comporti in modo lineare e prevedibile.

3.6 Goodness of Fit




Figura 8: Goodness of Fit: Analisi Valori Predetti vs Osservazioni Reali

Interpretazione Grafico

In questo grafico di Goodness of Fit ho messo a confronto le osservazioni reali con i valori predetti dai modelli. La linea di riferimento rossa rappresenta la previsione perfetta.

Come si può notare, i Polinomi e la Spline Lineare presentano un errore sistematico: le loro nuvole di dispersione si incurvano rispetto alla bisettrice, dimostrando una tendenza a sovrastimare i carichi bassi e sottostimare i picchi di consumo termico estremo.

Il modello vincitore è chiaramente la Spline Non Lineare (in basso a destra). Grazie all'uso delle basi quadratiche, la nuvola di dispersione si raddrizza, allineandosi in modo simmetrico e non distorto lungo la linea ideale per tutto lo spettro dei dati. Questo dimostra che il modello spline non lineare sembra ridurre alcune distorsioni sistematiche rispetto agli altri modelli.

3.7 Analisi dei Residui




Figura 9: Analisi dei Residui

Interpretazione Grafico

- **1° Grafico - Residui rispetto alla Temperatura Media:** Il primo pannello a sinistra evidenzia una chiara violazione dell'assunzione di invarianza della varianza (omoschedasticità). Sebbene la nuvola di dispersione sia globalmente centrata attorno allo zero, la sua ampiezza muta significativamente al variare della temperatura. Nello specifico, si osserva una dispersione ridotta nelle fasce termiche moderate (circa 50-60 °F, la cosiddetta "comfort zone"), mentre la varianza dell'errore esplode agli estremi del dominio (sotto i 40 °F e, in modo ancora più marcato, sopra gli 80 °F). Questo indica che il modello fatica a prevedere con precisione l'esatta magnitudo dei picchi di carico durante le giornate di freddo o caldo anomalo, suggerendo l'esistenza di dinamiche non spiegate dalla sola variabile meteorologica.
- **2° Grafico - Residui rispetto all'Ora del Giorno:** Plottando i residui del modello puramente termico contro la variabile oraria (0-24), emerge un fortissimo pattern deterministico di natura sinusoidale. Il modello tende sistematicamente a sovrastimare i consumi durante le ore notturne (residui negativi) e a sottostimarli drasticamente nelle ore pomeridiane e serali (residui positivi). Questa evidente struttura ad "onda" nei residui rappresenta la prova matematica che nel modello manca una componente esplicativa fondamentale: la ciclicità della routine umana e dei processi produttivi.
- **3° Grafico - Distribuzione dei Residui:** Il terzo pannello a destra mostra la densità di probabilità degli errori. La distribuzione appare simmetrica e centrata sullo zero, confermando che il modello è globalmente corretto e non presenta un bias di previsione sistematico (non stima "sempre in eccesso" o "sempre in difetto"). Tuttavia, rispetto a una gaussiana perfetta, la campana si presenta leggermente leptocurtica (con code più pesanti del normale). Ciò implica che errori di grossa entità (gli outlier visibili nei precedenti scatterplot) si verificano con una frequenza maggiore rispetto a quanto atteso in una distribuzione puramente normale.

Interpretazione Grafico

L'analisi diagnostica conferma che la sola temperatura media, pur modellata in modo non lineare tramite l'impiego di spline, è insufficiente a descrivere la complessità del carico elettrico sulla rete. L'evidente pattern ciclico lasciato nei residui giustifica rigorosamente la necessità di espandere l'architettura predittiva, passando a un modello multivariato in grado di integrare la variabile temporale attraverso l'uso di serie armoniche.

4 Punto 4

Fittare un modello ai minimi quadrati usando tutte le 25 variabili di temperatura e discutere eventuali problemi di collinearità e di non significatività di alcuni coefficienti.

L'uso simultaneo delle 25 temperature in una regressione OLS può portare a stime instabili dei coefficienti, a causa della forte multicollinearità tra i regressori.

4.1 Il problema di fondo - La Collinearità

Se gli dai 25 stazioni meteo, lui cerca di calcolare un peso (β) per ognuna di esse. Ma ricordando la heatmap tutta gialla del Punto 2, sappiamo già che le stazioni registrano la stessa identica temperatura (es. se ci sono 30°C alla stazione 1, ci sono 30°C anche alla stazione 2, alla 3, ecc.). In statistica, quando due o più variabili predittive sono quasi identiche, si parla di **Multicollinearità**.

La multicollinearità è un fenomeno statistico che si verifica nei modelli di regressione multipla quando due o più variabili indipendenti (predittori) sono altamente correlate tra loro.

In sintesi significa che le variabili stanno fornendo all'algoritmo informazioni ridondanti (come avere due sensori di temperatura posizionati a pochi metri di distanza).

4.2 Le soluzioni

Ottimizzazione Computazionale (Subsampling)

Inserire 25 temperature nel modello causa instabilità matematica (matrice Rank Deficient) perché le informazioni sono ridondanti. Molti coefficienti risultano statisticamente non significativi (p-value alti).

```
--- PUNTO 4: SELEZIONE DELLE VARIABILI E GESTIONE COLLINEARITA' ---
--- RIDUZIONE DEL COSTO COMPUTAZIONALE (SUBSAMPLING) ---
Al fine di abbattere il costo computazionale e i tempi di calcolo,
è stato applicato un campionamento casuale (subsampling) al training set.
-> Numero iniziale di osservazioni: 40300
-> Numero finale di osservazioni utilizzate: 4030 (10%)

--- ANALISI OLS: IL PROBLEMA DELLA MULTICOLLINEARITA' ---
Fit di un modello lineare (Minimi Quadrati Ordinari) con tutte le 25 stazioni.
=> SINTESI: 13 coefficienti su 25 (52.0%) risultano NON significativi (p-value > 0.05).
Questo conferma l'elevata ridondanza e l'instabilità del modello globale.
Di seguito un estratto dei coefficienti OLS (Stima, Errore Standard, p-Value):
```

	Estimate	SE	tStat	pValue
(Intercept)	109.44	3.7376	29.28	6.119e-171
x1	-0.13815	0.19319	-0.71513	0.47457
x2	0.90139	0.24261	3.7154	0.00020567
x3	-0.062115	0.19996	-0.31063	0.75609
x4	-0.11119	0.42945	-0.25892	0.79571
x5	1.0864	0.26049	4.1706	3.1018e-05
x6	-0.70536	0.32324	-2.1822	0.029154
x7	0.39287	0.39797	0.9872	0.3236
x8	0.41764	0.23678	1.7639	0.077832
x9	-0.42709	0.1683	-2.5376	0.011199
x10	0.96138	0.28871	3.33	0.00087646
x11	-0.33837	0.34153	-0.99076	0.32186
x12	-0.87851	0.26853	-3.2715	0.0010787
x13	-0.30737	0.18647	-1.6484	0.099347
x14	0.76266	0.2254	3.3836	0.00072225
x15	-1.0472	0.35563	-2.9446	0.0032525
x16	-1.5545	0.30607	-5.0789	3.9689e-07
x17	0.64126	0.39596	1.6195	0.10541
x18	-0.36552	0.31112	-1.1748	0.24013
x19	1.2815	0.21176	6.0519	1.5629e-09
x20	-0.48543	0.38163	-1.272	0.20345
x21	-0.092642	0.24703	-0.37503	0.70766
x22	-0.34833	0.33142	-1.051	0.2933
x23	-1.4334	0.27379	-5.2354	1.7308e-07
x24	1.8771	0.40852	4.5948	4.4659e-06
x25	0.5634	0.36424	1.5468	0.122

Figura 10: Tabella Coefficienti OLS

4.2.1 Stepwise

- **Stepwise Forward:** Parte da zero e aggiunge la stazione migliore finché l'errore non smette di scendere. È conservativo e veloce.
- **Stepwise Backward:** Parte con tutte e 25 le stazioni e rimuove la peggiore ad ogni ciclo. Utile per vedere l'impatto globale prima di sfoltire.
- **Stepwise Hybrid:** Fa entrambe le cose, può aggiungere e poi rivalutare rimuovendo.

4.2.2 Regularizzazione LASSO - Least Absolute Shrinkage and Selection Operator

È il metodo più elegante. Invece di accendere/spegnere le variabili, applica una penalità geometrica continua (L_1). Decrementa progressivamente a zero i pesi delle stazioni inutili. Matematicamente, aggiunge alla funzione di costo una penalità chiamata L_1 , che è basata sulla somma del valore assoluto di tutti i coefficienti del modello ($\sum |\beta_j|$). L'entità di questa penalità è governata da un singolo iperparametro di regolarizzazione, chiamato λ (Lambda). Il LASSO non si limita a rimpicciolire i coefficienti delle variabili ridondanti, ma li schiaccia esattamente a zero.

Prima di applicare la penalizzazione L_1 del LASSO, tutti i regressori sono stati rigorosamente **standardizzati**. Questo passaggio è essenziale: avendo i regressori scale differenti, senza una standardizzazione la penalizzazione colpirebbe in modo iniquo le variabili con magnitudo numerica maggiore.

Inoltre, osservando il grafico di Shrinkage, e il grafico della Cross-Validation, notiamo un andamento diagnostico chiaro: l'RMSE di validazione rimane stabile e piatto per valori di penalizzazione deboli, fino a circa $\lambda = 10^{-1}$, per poi aumentare bruscamente quando la penalizzazione diviene troppo severa e comincia ad azzerare predittori fondamentali.

- Se $\lambda = 0$: Nessuna penalità. Il modello usa tutte le variabili (è una regressione normale).
- **Aumentando gradualmente λ :** Il modello inizia ad azzerare le variabili deboli, ridondanti o rumorose, portando il loro peso a 0.000.
- Se λ è infinito: La penalità è insostenibile, tutti i coefficienti vengono azzerati.




Figura 11

Interpretazione grafici

- **Grafico a Sinistra:** Per trovare il numero perfetto di variabili, ho usato una Cross-Validation a 5 fold. Guardando la curva rossa da destra verso sinistra, notiamo che l'errore inizialmente scende eliminando le stazioni inutili: questo dimostra che togliere la collinearità migliora le previsioni. Il cerchio verde indica il modello con l'errore minimo assoluto. Il cerchio blu rappresenta invece un modello più parsimonioso (con meno variabili) garantito dalla regola di un standard error il cui errore di validazione è entro un errore standard dal minimo stimato.
- **Grafico a Destra:**
 - **A destra (λ basso):** Le penalità sono basse, il modello si tiene tutte e 25 le stazioni con pesi sballati e instabili.
 - **Spostandosi verso sinistra (λ cresce):** Le penalità si alzano. Inizia lo shrinkage. Le linee vengono attratte verso l'asse dello zero. Le prime a toccare lo zero sono le stazioni inutili, che vengono spente definitivamente. Le stazioni "leader", quelle che contengono la fisica vera del fenomeno, resistono più a lungo, ma i loro pesi vengono comunque smorzati (compressi) per evitare l'overfitting.

Svolgimento

Arrivati al Punto 4, l'obiettivo era selezionare le stazioni meteorologiche più rilevanti per combattere la collinearità spaziale. Tuttavia, applicare direttamente un algoritmo lineare come lo Stepwise o il LASSO classico su tutte le 25 stazioni avrebbe introdotto un grave errore concettuale. Come abbiamo dimostrato nel Punto 3, il consumo elettrico ha un comportamento non lineare a forma di 'V': scende fino a una temperatura di comfort attorno ai 60 gradi Fahrenheit, per poi risalire a causa dell'accensione dei condizionatori. Chiedere a un algoritmo di tracciare una singola linea retta che valga per tutto l'anno avrebbe significato distorcere la realtà fisica del fenomeno.

Utilizzando il 'nodo termico' ottimale individuato in precedenza, ho letteralmente diviso a metà ogni stazione meteorologica. Matematicamente, le 25 stazioni fisiche sono state trasformate in 50 'rami termici' virtuali: 25 variabili che si attivano solo in regime invernale, e 25 che si attivano solo in regime estivo. In questo modo abbiamo fornito al LASSO la corretta geometria del problema su cui lavorare.

L'algoritmo non ha selezionato tutte le variabili, ma si è fermato a 44. Questo significa che ha portato a zero esattamente 6 rami termici, scartandoli come rumore o ridondanza. La vera scoperta risiede nel fatto che il LASSO ha scartato in modo asimmetrico. Spegnendo, ad esempio, il ramo estivo di una specifica stazione ma mantenendo il suo ramo invernale, il modello ci sta dimostrando matematicamente che la geografia dei consumi cambia con le stagioni. Le stazioni meteorologiche che guidano l'assorbimento elettrico per il riscaldamento non sono necessariamente le stesse che spiegano i picchi estivi di condizionamento. Il LASSO ha compreso e modellato questa dinamica. L'idea di sdoppiare le variabili originali in rami termici 'freddo' e 'caldo' attraverso hinge functions si è rivelata coerente con la forma a U della curva termodinamica. Tuttavia, richiede cautela interpretativa. Il fatto che il LASSO selezioni alcune stazioni per il regime invernale e altre per quello estivo non dimostra causalmente un cambio geografico nei consumi della facility. Più prudentemente, suggerisce che certe stazioni (o particolari combinazioni lineari tra esse) risultino algoritmicamente più utili a spiegare la varianza in specifici regimi termici. Per trarre forti conclusioni fisiche o geografiche sulla rete elettrica, servirebbero ulteriori indagini e dati sulla demografia delle zone coperte dai sensori.

Trade-off Min MSE vs Regola 1-SE

Analizzando i risultati della Cross-Validation del LASSO, emerge un importante trade-off analitico. Il modello corrispondente al minimo errore quadratico medio assoluto (λ_{min}) seleziona un numero molto elevato di variabili (circa 44 rami termici). Tuttavia, applicando la regola conservativa di un Errore Standard (1-SE), otteniamo un modello drasticamente più parsimonioso (selezionando solo una ventina di variabili) con un deterioramento delle prestazioni predittive statisticamente trascurabile. Rinunciare a una frazione decimale di RMSE per dimezzare la dimensionalità del modello garantisce una maggiore stabilità della selezione, una resistenza superiore all'overfitting sui dati futuri e, soprattutto, una migliore interpretabilità operativa.

Tabella Risultati Conclusionale

--- RISULTATI CONFRONTATI (Validati sul Validation Set) ---		
	Selected_Variables	RMSE_Validation_Set
Forward (Lin)	10	44.449
Backward (Lin)	15	44.405
Hybrid (Lin)	15	44.405
LASSO (Spline MinMSE)	44	37.915

Figura 12: Confronto risultati

Interpretazione Immagine

Come mai backward e hybrid hanno selezionato le stesse stazioni? è un risultato plausibile?

Sì, è un risultato atteso e molto rassicurante. Avendo inizializzato l'Hybrid dal modello completo per esplorare lo spazio dall'alto verso il basso, esso ha iniziato a scartare le variabili seguendo i p-value, proprio come il Backward. Il fatto che l'Hybrid non abbia mai sentito il bisogno di fare un 'passo indietro' per reinserire una variabile precedentemente scartata, significa che la struttura di collinearità era netta: le variabili rimosse erano puro rumore. Questa convergenza dimostra che il sottoinsieme di stazioni che abbiamo trovato è un minimo globale stabile.

In figura si possono notare i RMSE dei vari modelli.

Confronto finale

Confrontando i tre approcci lineari di feature selection, notiamo che i metodi Backward e Hybrid tendono a selezionare insiemi di variabili molto simili tra loro. È imperativo ricordare che le procedure stepwise sono algoritmi greedy, esplorano solo percorsi locali e non garantiscono matematicamente il raggiungimento dell'ottimo globale dello spazio dei regressori. Pertanto, questa convergenza non dimostra l'individuazione del 'minimo globale assoluto', ma suggerisce più prudentemente una rassicurante stabilità della selezione spaziale rispetto alle specifiche procedure iterative utilizzate.

5 Punto 5

Fittare un modello tra LOAD e l'ora del giorno come unico regressore;

5.1 Grafico del Modello LOAD - TIME




Figura 13: Modello Timestamp vs Load

Come si può notare dallo scatterplot, il grafico mostra una struttura giornaliera del carico, con valori diversi nelle varie fasce orarie.

La dispersione verticale a parità di ora può essere dovuta a diversi fattori, tra cui la temperatura; non possiamo però commentare con certezza altri fattori non osservati, come stagione, giorno della settimana, uso dell'edificio o comportamento delle persone. La nuvola di punti non è casuale, ma forma una chiara 'doppia gobba': abbiamo consumi minimi durante la notte, una rapida salita al mattino con il risveglio della città, e il picco massimo concentrato nelle ore serali. La forte dispersione verticale, a parità di ora, è invece governata dalla temperatura, come evidenziato dalla scala cromatica.

L'algoritmo ha trovato il miglior modello polinomiale per fittare questo andamento orario e il risultato vincente è stato: **il Polinomio di Grado 5** con un RMSE di 42.94.

Tuttavia, analizzando visivamente il comportamento di questa curva, emerge un grave limite concettuale, le due estremità del grafico: le ore 0 e le ore 24. A mezzanotte la curva parte da un valore di carico intorno a 125, ma alla mezzanotte successiva crolla in modo del tutto innaturale verso quota 95.

Questo accade perché i polinomi, per natura, non sono funzioni cicliche. Sono rigidi e soffrono di distorsioni agli estremi. Il modello ignora del tutto un fatto fisico fondamentale: la fine di una giornata deve raccordarsi in modo fluido e continuo con l'inizio della successiva.

5.2 Soluzione - Modello Armonico

Per superare questo ostacolo e imporre rigorosamente il vincolo di periodicità $f(0) = f(24)$, si è optato per un approccio trigonometrico basato sullo sviluppo in Serie di Fourier. La variabile oraria t è stata mappata su un periodo di 24 ore e modellata attraverso una combinazione lineare di funzioni armoniche (seni e coseni):

$$f(t) = \beta_0 + \sum_{k=1}^K \left(\alpha_k \sin\left(\frac{2\pi kt}{24}\right) + \gamma_k \cos\left(\frac{2\pi kt}{24}\right) \right)$$

Questa formulazione matematica garantisce per costruzione la continuità della funzione e delle sue derivate agli estremi del dominio. Il parametro K (numero di armoniche) regola la flessibilità della curva: valori più alti permettono di catturare dinamiche di breve durata (come improvvisi picchi mattutini), ma espongono il modello al rischio di overfitting. La scelta del numero ottimo di armoniche è stata condotta valutando il Criterio di Informazione di Akaike (AIC) bilanciato con il principio di parsimonia.




Figura 14: Modello Timestamp vs Load

Sovrapposta alla linea tratteggiata del polinomio, ho tracciato in rosso Modello Armonico ottimizzato, che l'algoritmo ha calibrato su 7 frequenze ($k = 7$). Uno sguardo di nuovo agli estremi del grafico: a differenza del polinomio che 'cade' nel vuoto verso le ore 24 perdendo il senso fisico del fenomeno, l'onda armonica garantisce una continuità matematica perfetta. Il carico previsto alle 23:59 si raccorda esattamente con quello delle 00:00. Il modello ha finalmente 'capito' che la giornata è un ciclo chiuso. Inoltre, grazie alla somma di seni e coseni, l'onda rossa si muove con estrema naturalezza attraverso i dati. Riesce a catturare fedelmente il calo notturno, la ripresa mattutina e il picco massimo del tardo pomeriggio. Questa linea rossa rappresenta la vera 'spina dorsale' della routine quotidiana. Tuttavia, guardando i colori dello scatterplot, è evidente che l'ora del giorno da sola non basta: a parità di ora, il carico può raddoppiare a causa delle temperature estreme (i punti rossi e blu).

Motivazione della scelta




Figura 15: Riduzione dell'errore all'aumentare delle armoniche

Per determinare il numero ottimale di armoniche (k) abbiamo minimizzato il Criterio di Informazione di Akaike (AIC). L'algoritmo ha individuato il minimo teorico a $k = 7$. Tuttavia, è fondamentale una lettura critica di questo risultato. Nelle serie storiche con decine di migliaia di osservazioni (elevato N), la penalizzazione matematica introdotta dall'AIC per l'aggiunta di nuovi parametri diventa marginale rispetto al guadagno sulla Log-Likelihood. L'osservazione visiva della curva AIC rivela infatti che un modello con appena $k = 2$ o $k = 3$ armoniche cattura già la quasi totalità della macro-struttura giornaliera (il ciclo del sonno, il picco mattutino e quello preserale). L'uso di $k = 7$ modella micro-dinamiche statistiche che, in un contesto reale, rischiano di sfociare nell'overfitting. In un'implementazione ingegneristica operativa, si potrebbe ragionevolmente optare per un $k = 3$, rinunciando a una frazione di RMSE in cambio di un modello estremamente più parsimonioso e interpretabile.

Sebbene l'implementazione di una Spline lineare con nodi strategici (es. ore 6, 12 e 18) sembri ricalcare bene i picchi di consumo giornalieri, nasconde una grave falla metodologica: l'assenza di periodicità intrinseca. A differenza delle funzioni trigonometriche (Seni e Coseni), una normale spline lineare non è vincolata ad avere lo stesso valore all'inizio e alla fine del dominio ($f(0) = f(24)$). Se non si applicano complessi vincoli di uguaglianza ai bordi durante il fit dei minimi quadrati, la spline oraria genererà una discontinuità fisica a mezzanotte (un 'salto' irrealistico nei consumi tra le 23:59 e le 00:01). Per questo motivo, pur avendo un RMSE comparabile, abbiamo decretato il Modello Armonico come superiore, in quanto garantisce la chiusura ciclica perfetta del giorno.

6 Punto 6

Fittare un modello tra LOAD, $w(t)$ (media) e l'ora del giorno;

6.1 Intuizione

Il tempo da solo non basta, perché ignora il meteo

Per capire esattamente come il meteo influisce sulle singole ore, ho sezionato il dataset in 24 finestre orarie




Figura 16: Grafici del carico per ogni ora

Analizzando le ore singolarmente la forma a 'U' diventa molto più pulita (basta un grado quadratico). Ma soprattutto, notiamo che il vertice di minimo consumo si sposta: la temperatura ideale di comfort cambia tra il giorno e la notte. Questo spostamento dimostra che non possiamo usare un semplice modello additivo, ma ci serve un modello con interazione tra temperatura e orario e componenti più avanzate per raddrizzare questo vertice.

Analisi Vertici




Figura 17: Analisi Dei Vertici

I vertici che si spostano dicono che il comportamento umano e fisico non è costante. Ecco i due motivi principali per cui questo fenomeno "comanda" la scelta del modello:

1. Lo spostamento Orizzontale (Asse X): La Temperatura di Comfort

Il vertice sulla X rappresenta la temperatura esterna in cui il consumo è minimo (non serve né riscaldamento né aria condizionata).

- Se alle 14:00 il vertice è a 70°F e alle 04:00 di notte è a 60°F, significa che la "zona di benessere" si è spostata. Questo dimostra che esiste una interazione. Non si può dire "se ci sono 65°F il consumo è X", perché la risposta corretta è: "dipende dall'ora". Alle 14:00 con 65°F si potrebbe accendere il riscaldamento, mentre alle 04:00 con 65°F si potrebbe già sentire caldo. Matematicamente, questo obbliga a usare termini come $T \times t$ nel modello.

2. Lo spostamento Verticale (Asse Y): Il Carico Base

Il vertice sulla Y rappresenta quanto consuma la rete elettrica quando la temperatura è perfetta.

- Anche se la temperatura è quella ideale, alle 20:00 si consumerà molto di più (luci, TV, forni) rispetto alle 03:00 del mattino. Permette di isolare la routine umana pura dal meteo. Dice quanto del carico totale è dovuto semplicemente al fatto che siamo svegli e attivi, indipendentemente dal fatto che faccia caldo o freddo.

In Sintesi

L'analisi dei vertici degli 'smile' orari rivela che **il punto di minimo consumo non è statico**. Lo spostamento orizzontale indica che la temperatura di comfort termico varia tra il giorno e la notte (inerzia termica e abitudini biologiche), mentre lo spostamento verticale isola il ciclo della routine umana (carico base). **Questa evidenza nega la validità di un semplice modello additivo e impone l'adozione di un modello a interazione**, dove l'effetto della temperatura è pesato diversamente a seconda dell'ora del giorno.

6.2 Performance Modello Armonico su dati Futuri




Figura 18: Modello armonico a interazione

Interpretazione

1. **La trasformazione del Tempo:**

Per rispettare la continuità della giornata, ho abbandonato i polinomi temporali e ho trasformato l'orario t in un segnale armonico calcolando $\sin(2\pi \frac{t}{24})$ e $\cos(2\pi \frac{t}{24})$. In questo modo l'algoritmo capisce che la mezzanotte è adiacente all'una del mattino.

2. **La Modellazione dell'Interazione:** Ho creato una matrice in cui la temperatura è moltiplicata per le sinusoidi e, matematicamente, questo significa che il peso della temperatura non è più fisso, ma oscilla dinamicamente al ritmo della giornata.

3. **Il Grafico:** Tracciando un grafico lineare su un campione temporale ristretto (es. tre giorni), possiamo vedere come la linea rossa del modello armonico inseguia quasi perfettamente l'onda blu dei dati reali, riproducendo sia il carico base notturno sia le impennate dei picchi diurni/serali.

Conclusione

L'inserimento dell'interazione armonica ha permesso al modello di flettere e adattare la curva di risposta termica in base al momento esatto della giornata, abbattendo drasticamente l'errore di previsione (RMSE) e dimostrando che il consumo elettrico è un fenomeno in cui meteo e comportamento umano sono inseparabili.

6.3 Superficie 3D




Figura 19

--- PUNTO 6: IL MODELLO FINALE (TEMPERATURA + TIMESTAMP) ---

=> RIEPILOGO PERFORMANCE (Validation Set):

- | | |
|---|-------|
| 1. Modello Base Termico (Polinomio Grado 5): | 23.19 |
| 2. Modello Base Temporale (Polinomio Grado 5): | 42.94 |
| 3. Modello Multivariato Additivo (Temp + Tempo): | 17.88 |
| 4. Modello Armonico con Interazione (Temp x Tempo): | 19.19 |
| 5. Modello 3D Additivo (Spline NL + Spline Oraria): | 19.38 |

Figura 20: Output Console MatLab

Ho unito la componente termodinamica e quella temporale in un unico modello multivariato. I risultati empirici danno subito una conferma: unire le variabili abbatte drasticamente l'errore. Il modello basato solo sul Tempo aveva un RMSE di quasi 43, mentre unendolo alla Temperatura tramite un **Polinomio Multivariato** di Grado 5, l'errore precipita al minimo assoluto di **17.88**. Se ci fermassimo puramente alla statistica, questo sarebbe il nostro modello vincitore.

Tuttavia non possiamo ignorare la fisica del fenomeno. Se guardiamo la superficie 3D generata da questo polinomio, notiamo un gravissimo errore concettuale agli estremi dell'asse temporale. Un polinomio non ha memoria ciclica: non sa che dopo le 23:59 arriva la mezzanotte. Di conseguenza, ai bordi del grafico, la superficie devia in modo innaturale e non si raccorda tra la fine di una giornata e l'inizio della successiva. Questo ci porta a una conclusione fondamentale: il modello di Grado 5 ha una struttura funzionale non coerente con la periodicità dell'ora del giorno. Può anche sovraddattare i dati, ma la mancata periodicità è già di per sé un problema strutturale.

7 Punto 7

Proporre un modello finale migliore usando una strategia ben motivata, ad esempio selezione stepwise, regressione regolarizzata, modelli non lineari o altre tecniche appropriate.

7.1 Modello finale e Rete Neurale




Figura 21

Spiegazione

- **Master Model Definitivo.** È un modello 'Grey Box' costruito su Spline non lineari per la temperatura e Armoniche ottimizzate per il tempo, unite da termini di interazione. Raggiunge un eccellente **RMSE di 15.17**. Il suo più grande pregio è l'assoluta coerenza fisica: la valle termica è morbida, la continuità tra la mezzanotte e il giorno successivo è geometricamente perfetta, quindi la sua struttura è coerente con alcune proprietà attese del problema: non linearità rispetto alla temperatura e periodicità rispetto all'ora del giorno.
- **Rete Neurale Artificiale a 15 neuroni.** La Rete ha imparato da sola a ricreare la complessa superficie del nostro Master Model, **abbassando ulteriormente l'errore a 14.68**. Tuttavia, la scelta del modello 'migliore' non dipende solo dall'RMSE. La Rete Neurale rimane una '**Black Box**': ci fornisce previsioni eccellenti, ma ci nasconde le regole. Il Master Model, pur cedendo una frazione decimale di precisione, ci garantisce totale interpretabilità, stabilità agli estremi e la sicurezza che le nostre previsioni seguano fedelmente le leggi della fisica e della routine umana. In un contesto operativo reale, dove bisogna prendere decisioni strategiche sull'infrastruttura energetica, l'interpretabilità del Master Model rappresenta il vero valore aggiunto.

8 Conclusioni e Sviluppi Futuri

8.1 Conclusioni

Tabella 1: Confronto delle performance e della complessità dei modelli analizzati.

Modello	Regressori	RMSE Val.	Param.
Polinomio G5	Temp. Media	23.18	6
Spline Lineare	Temp. Media (Hinge)	24.89	3
Spline Non Lin.	Temp. Media (Quadr.)	23.12	5
Stepwise (Fwd)	25 Stazioni	44.45	10
LASSO	50 Basi Spline	37.91	44
Armonico	Ora (Fourier)	19.19	15
Master Model	Temp + Ora + Int	15.17	47
Rete Neurale	Temp + Ora	14.68	76

8.2 Sviluppi Futuri: Recupero dell'Informazione Spaziale Sintetica

L'architettura del modello finale si fonda sull'utilizzo della Temperatura Media calcolata sull'intero network dei 25 sensori meteorologici. Se da un lato questa scelta ha risolto efficacemente il problema della severa multicollinearità (evidenziata nelle simulazioni OLS), dall'altro ha comportato un inevitabile appiattimento dell'informazione geografica, trattando la rete di distribuzione come un nodo termico puntiforme.

Un naturale e promettente sviluppo futuro di questo progetto risiede nel recupero dell'informazione spaziale senza incorrere nell'instabilità della multicollinearità. Un approccio metodologico robusto prevederebbe l'integrazione di features sintetiche, estratte tramite tecniche di riduzione della dimensionalità. Ad esempio, l'Analisi delle Componenti Principali (PCA) alle 25 stazioni oppure l'introduzione di un regressore basato sulla Varianza Spaziale (la deviazione standard delle temperature registrate in un dato istante) permetterebbe al modello di discriminare le giornate termicamente uniformi da quelle caratterizzate da forti microclimi locali, raffinando ulteriormente l'accuratezza predittiva.